

ライブ配信のチャットと LLM を用いた ユーザの嗜好に応じたダイジェスト動画生成システム

植野天翔 加藤卓哉 平井辰典
駒澤大学

1. はじめに

近年の動画配信サービスでは、ライブ配信が可能となっており人気を博している。ライブ配信はリアルタイムでのコンテンツ提供が可能のため、視聴者との直接的な交流ができることが大きな魅力である。

長時間行われるライブ配信には配信者と視聴者それぞれに関する課題がある。配信者は、長時間のライブ配信で視聴者と交流しながら視聴者の興味を保ち続ける必要がある。また、視聴者数の増加を目指すために、ライブ配信の要点や見所をまとめた「切り抜き動画」の作成を自ら行うか、視聴者に作成を依頼する場合もある。一方で視聴者は、長時間の配信をどのように視聴するかを考える必要がある。ライブ配信全てをリアルタイムで視聴する場合、チャットコメントの投稿を通して配信に参加できるが、視聴に時間を要する。部分的に視聴する場合、時間的な制約がなく視聴が可能だが、重要なシーンを見逃す可能性がある。アーカイブされた配信や「切り抜き動画」を視聴する場合、ライブ配信での能動的な体験が失われ、得られる内容が限られることになる。

そこで本研究では、ユーザが過去のライブ配信に対して付与したチャットコメントを基に、新たなライブ配信動画の中からユーザが特に関心を持つと考えられるシーンを自動で抽出し、それらを提示するシステムを提案する。

2. 関連研究

本研究の関連研究として、動画要約に関する研究が挙げられる。三浦ら[1]による研究では、料理映像の構成がパターン化されていることに注目し、映像を要約している。この手法では、本研究で対象とする、構成がパターン化されていない動画に対しては適用できない。

加藤ら[2]は、視聴者の表情から笑いや興奮といった感情を検出し、それに基づいて15分程の動画からダイジェスト動画を生成する手法を提案した。この手法では、視聴者は予め対象の動画を全て視聴する必要がある。また、視聴者の表情から感情分析を行うため、表情に出ない感情は考慮されない問題がある。

Moon ら[3]は、テキストを基にビデオクリップ内のシーンを特定する手法である CG-DETR モデルを提案している。こ




図1 提案システムの概要

のモデルは、ビデオクリップごとにテキストクエリとの関連性を評価し、適切なシーンを特定する。この手法はテキストクエリに依存するため、テキストクエリの質や具体性が結果に大きく影響する。一方で、ライブ配信のチャットコメントをテキストクエリとして使用する場合、視聴者のコメントが特定のシーンと直接関連しない場合が多いため、適切な動画シーンを特定できない。

本研究では、ライブ配信のチャットコメントを利用し、見所を推定することでダイジェスト動画を生成する。また、個人の好みに合わせた動画を提示するために、これまでユーザが投稿してきたチャットコメントを利用し、ユーザの好みに合わせた動画シーンの提示を行う。

3. チャットコメントと ChatGPT を利用したダイジェスト動画の生成

本研究では、ユーザの好みに合ったダイジェスト動画を生成するために、ライブ配信のチャットコメントと汎用的な大規模言語モデル（LLM）である ChatGPT を利用する。図1に提案システムの概要を示す。

3.1 ユーザデータの収集

ユーザの好みに関するデータ収集のために YouTube 上でユーザが過去に投稿したチャットコメントデータを Google マイアクティビティ上から取得し、システムにアップロードする。これにより、ユーザが今までにどのようなチャットコメントを送信したのかがシステムに保存される。

3.2 ChatGPT モデルのファインチューニング

3.1 節で取得したデータを使用し、ユーザの嗜好を ChatGPT モデルに学習させるためのファインチューニングを行う。ベースモデルの選定にあたり、GPT-4 は2023年時点でファインチューニング API の使用が特定ユーザに限られていたため、採用を見送った。代わりに、本研究ではベースモデルとして利用できるモデルの中で最も新しい gpt-3.5-turbo-1106 を選択した。

3.3 ChatGPT による評価値の推定

ファインチューニングした ChatGPT モデルを使用し、対象とする動画のチャットコメントの評価値を推定する。ChatGPT が各コメントに対して付与する評価値のデータは 0 か 1 となっている。ノイズが多いコメントに対する評価値データを時系列データとして扱い易くするため、評価値の移動平均 MA を計算式 (1) により求め、使用する。

$$MA_i = \frac{\sum_{j=i-49}^i s_j}{50} \quad (1)$$

この式は、各 i 番目の評価値 s に対して、その点とその前の 49 個の s (合計 50 個の s) の平均を計算したものである。

3.4 ダイジェスト動画の提示

ユーザに動画のシーンを提示するためには、動画のどの時刻の評価値が高かったのかを特定する必要がある。評価値の移動平均の上位 10 件を選択すると、同じ時間帯に集中する現象が起きる。これはライブ配信内の事象に対して、視聴者がそれに関連するチャットコメントを同じ時間に多く投稿する傾向があるためである。そこで、K 平均法を使用して評価値のクラスタリングを行うことで同じ時間帯からの選択を防ぎ、評価値が高く時間的に分散した 10 件の異なるシーンを選択した。ここで取得したシーンの時刻は、ライブ配信上でのコメント入力に伴うラグを考慮し、選択された時刻から 10 秒引いた時点のシーンをユーザの好みに合っているシーンとして提示する。提示する際には、どの時刻で評価値が高かったのかが直感的に分かるように図 2 のようなグラフを提示する。このグラフでは縦軸に評価値の移動平均、横軸に動画の時刻を設定しており、K 平均法によりクラスタリングされた各クラス内で最も評価値の移動平均が高かった時間に赤い破線を表示している。

本システムの動画シーン提示画面では、YouTube の埋め込み機能を利用し、図 3 のように評価値が高かった動画シーンがランキング形式で表示され、動画をクリックするとすぐに当該のシーンが再生されるようになっている。

4. 結果

今回制作したシステムについて、20 代の男女 5 人を対象としたシステムの評価実験を実施した。対象とする動画は 1 ～ 3 時間の長さの動画 12 件で、雑談配信 4 件とゲーム配信 8 件が含まれている。評価には Google Form を使用し、システムによって提示された 10 件のシーンに対して、シーン毎に 1 つずつ、5 段階の評価値を付与してもらった。評価値は「1: 自分に合っていないシーン」～「5: 自分に合っているシーン」として、高いほど好意的な評価となる。

評価実験の結果、全被験者の全シーンに対する評価値の平均は 3.32、分散は 1.7 となった (いずれの値も小数点以下 3 位で四捨五入)。評価値の平均が 5 段階評価の 3 を超えていることから、提案システムを使うことで、ユーザの好みに合わせたシーンの提示ができた。




図 2. 提示するグラフの例



図 3. 動画提示画面の例 (動画出典: さなちゃんねる,

<https://www.youtube/watch?v=pNdQAAi8hNI>)

5. まとめ

本研究では、ユーザのチャットコメントと大規模言語モデル (LLM) である ChatGPT を利用して、ユーザの好みに合う動画シーンを提示するシステムを提案した。実験の結果、ユーザの见たいシーンが提示できることが確認された。

今後の課題として、YouTube の動画再生履歴や、ユーザがよく見るシーンなどのデータを活用し、新たなユーザの好みのパターンを把握することを検討している。

参考文献

- [1] 三浦宏一, 浜田玲子, 井手一郎, 坂井修一, 田中英彦. 料理映像の特徴を利用した要約手法の検討. 電子情報通信学会技術研究報告. 2002. 102 (155). p.15-20.
- [2] 加藤宏和, 菰田昇平, 古川裕士, 森本光紀, 濱川礼. 視聴者の表情を用いた動画ダイジェスト作成システム. 第 74 回全国大会講演論文集. 2012. 2012 (1). p.207-208
- [3] W. J. Moon, S. Hyun, S. Lee, and J.-P. Heo, "Correlation-guided Query-Dependency Calibration in Video Representation Learning for Temporal Grounding," arXiv preprint arXiv:2311.08835, Nov. 2023.