

演技感情と推定感情のタグを付与した感情音声コーパスの構築*

○目良和也, △谷有希, △村田唯, △黒澤義明, 竹澤寿幸 (広島市立大)

1 はじめに

現在、機械学習を用いた音声からの感情推定に関する研究が盛んにおこなわれている^[1,2]が、機械学習を行うためには正解タグが付与された大量の学習データが必要となる。研究で利用可能な感情音声コーパスとしては、FAU Aibo Emotion corpus^[3]やオンラインゲーム感情音声コーパス^[4]など、さまざまなものが提供されている。これらは音声の収集方法、分類される感情の種類、データ数、感情の度合の意味、話されている言語など多様な違いがあり、研究者の研究目的に完全に合致したコーパスがうまく見つからないことも多い。

筆者らはこれまで、発話音声から推定した話者感情を考慮した自然言語対話システム^[5]の開発を行っていたが、今後本対話システムに組み込んでいる感情推定器を改良するにあたって、以下のような条件の感情音声コーパスが必要となった。

- A) 扱う感情の種類が、快不快軸および覚醒度軸の二次元平面を網羅できるように分布していること
- B) 感情種別の評価の際に発話文字列の影響を受けていないこと
- C) 音声データに付与されている感情の度合が、強度ではなく確信度であること
- D) 1つの音声データに付与される感情の種類が複数選択可能であること

そこで筆者らは、これらの条件を満たすため、以下のような手順で新たに感情音声コーパスを構築した。

- A') 快不快軸および覚醒度軸の度合に基づく3×3のグリッドを提示し、各グリッドに合う感情名を質問紙調査により収集する
- B') 同一の発話文字列に対して異なる感情を込めた演技音声を収集する

- C') ある感情クラスを選択した人数を確信度として扱えるようにするため、感情クラスの評価者の数を11名に増やす
- D') 感情クラスを複数選択可能にする

本稿では本コーパスの概要を説明するとともに、本コーパスを用いて構築した機械学習器の性能についても評価する。

2 感情クラスの設定

音声データに付与する感情ラベルの種類を定義するため、まず快不快軸の3段階の度合（快／中立／不快）と覚醒度軸の3段階の度合（高い／普通／低い）を組み合わせた9種類の心理状態に適合する感情名を、21～23歳の大学生6名（男性4名、女性2名）から自由回答で収集した。結果をTable 1に示す。

Table 1の収集結果とRussellの感情円環モデル^[6]に配置されている感情名を比較検討した結果、本コーパスでは“狂喜・楽しい”、“不安・緊張”、“怒り”、“恐れ”、“余裕・嬉しい”、“冷静”、“嫌い”、“軽蔑”、“リラックス・気楽”、“眠い・疲れた”、“憂鬱・悲しい”の11種類の感情クラスを定義した。Fig. 1にRussellのモデルに各感情クラスの位置を重ねた図を示す。なお、1つの感情クラスに2つの感情名を提示しているものがあるが、これは2つの感情のANDの状態をイメージしてもらうことで、感情名の語義の曖昧性を軽減することを意図している。

Table 1 Collected emotions on valence and arousal dimensions

		快不快軸		
		不快	中立	快
覚醒度軸	高	激怒, 怖い, 怒り, 激おこ	恥ずかしい(×2), 期待	狂喜, 最高, 楽しい, 感動
	中	嫌い, 不安, 寂しい	冷静, 無感動, 無関心	嬉しい, 安心, 余裕
	低	惨め, 鬱, 悲しい, 後悔	眠い(×2), 空しい	落ち着く, 優越, 憧れ

* Designing emotional speech corpus annotated both acted emotion and estimated emotion, by MERA, Kazuya, TANI, Yuki, MURATA, Yui, KUROSAWA, Yoshiaki, and TAKEZAWA, Toshiyuki (Hiroshima City University).




Fig. 1 Defined emotion classes on valence and arousal dimensions

3 感情音声データの収録

3.1 収録する感情音声のタイプ

自発的な感情表出から話者感情を推定する場合、学習データとして演技音声を用いると感情表現が大げさになり、日常生活で人間が表出している感情表現とは異なると言われていた^[4]。筆者らの構築する対話システムにおいても、自発対話音声からの感情推定を目的としている。しかし、感情誘導の無い自然な対話では生起する感情に偏りが出てしまうため一部の感情は十分な数を収録できない恐れがあることと、同一の発話文字列でも異なる感情を表出している音声データが必要であることから、本コーパスでは条件をコントロールしやすい演技音声を収録対象とした。

演技者は、ある程度各感情表出に違いが出ること、かつ、プロの声優が習得している伝える技量を使った演技っぽさが出すぎないことを考慮して、声優学校に在籍する1年生(19～26歳の男女各3名)に依頼した。出身地は広島県5名、島根県1名である。

3.2 感情音声データの収録手順

3.1節の演技者6名それぞれに、事前に選定した10種類の台詞(後述)を2節の11種類の感情を込めて3回ずつ発声してもらった。3回の発声は、可能であれば少しずつ違いをつけてもらった。この収録作業を日を分けて3回行った。収録された感情音声の総数は、10

台詞×11感情×3パターン×6演技者×3回＝5940発話となった。

演技者に発声してもらう台詞は、高木らの感情知覚実験^[7]やドラマ映画脚本等から収集した台詞から特定の感情を想起させない発話文字列である台詞を10個選定した。選定された台詞は「そうなんですか」、「どうなってるの」、「わかりました」、「ありがとう(ございます)」、「覚えてますか」、「全然嬉しくない」、「それはできない(よ)」、「気にしないで」、「仕方ないな」、「ごめんなさい」の10個である。

4 感情ラベルの付与

ある人物が発話した際に付随する感情には話者自身に生起している感情、話者が表出している感情、相手が知覚している感情の3種類がある。感情推定器がどのレベルの推定を必要とするかは用途によって異なる。心療内科医やカウンセラーのような働きを求めするのであれば、一般的な人や自分自身でさえも気づいていないような感情の動きを検出する必要がある。しかし日常的な応対や雑談をするうへでは、一般的な人が相手の状態から感情を察するレベルの感情推定性能で十分である。

本コーパスでは、各感情音声に対して3種類の感情ラベルを付与する。一つは収録の際に指示した演技感情である。これは話者が表出しようとして表出している感情に相当する。残りは聞き手による知覚感情のラベルである。一つは次元説に基づき、快不快の度合と覚醒の度合をそれぞれ7件法(とても〇〇である/〇〇である/少し〇〇である/どちらでもない/少し△△である/△△である/とても△△である)で回答する。もう一つは基本感情説に基づき2節の11種類の感情クラスから話者感情に該当するものを回答する。なお回答は複数選択可能である。

本稿では1回目の収録で得た1,980発話に対して前述の2種類の知覚感情のラベルを付与するため、各発話に対して21～24歳の大学生11名(男性8名、女性3名)の評価者が評価を行った。1,980発話について各感情クラスに該当すると評価した人数ごとの発話データ数をTable 2に示す。

5 機械学習による感情推定実験

本節では作成した感情音声コーパスを学習データとして、特定の感情か否かを判別する

Table 2 Distribution of utterance data annotated emotion class

		回答人数												データ 合計
		0	1	2	3	4	5	6	7	8	9	10	11	
感情 クラ ス	狂喜・楽しい	1,490	190	72	46	37	25	23	28	19	17	25	8	1,980
	余裕・嬉しい	1,164	241	103	60	70	61	47	49	57	58	45	25	1,980
	リラックス・気楽	1,052	272	144	74	79	74	84	66	60	46	20	9	1,980
	眠い・疲れた	1,034	428	185	93	53	39	36	31	19	32	19	11	1,980
	冷静	755	424	238	153	99	79	65	41	50	39	24	13	1,980
	不安・緊張	842	372	147	101	75	72	82	72	81	70	41	25	1,980
	憂鬱・悲しい	839	368	191	131	97	90	77	59	51	43	28	6	1,980
	恐れ	1,156	265	106	68	72	78	77	71	41	29	14	3	1,980
	怒り	1,019	271	124	81	68	74	69	59	59	53	56	47	1,980
	嫌い	921	261	147	94	93	80	92	112	81	69	26	4	1,980
	軽蔑	1,033	367	211	114	75	62	40	29	21	14	13	1	1,980

2 クラス分類器と複数の感情クラスから 1 つを選択する多クラス分類器を構築し、感情推定の正解率について考察する。

5.1 実験条件

機械学習器として Support Vector Machine (SVM) を用いた。また、機械学習に使用する素性値は、28 種類の特徴量（音のエネルギー、メル周波数ケプストラム[1]～[12]、基本周波数およびこれらの一次微分）の変化曲線から算出される 12 種類の基本統計量 (Table 3 参照) である。素性値の数は計 $28 \times 12 = 336$ 種類となる。そして算出した素性値に規準化（平均=0、分散=1）を行う。評価は Leave-one-out 交差検定法によって行う。

5.2 特定の感情か否かの 2 クラス判別実験

11 種類の各感情クラスに対して、それぞれ当該感情か否かを判別する分類器を SVM を用いて構築した。Table 2 で回答した人数が 8 人以上の音声データを true データ、回答人数が 0 人の音声データを false データとして用いた。ただしそのままでは false データの数が多いため、false データの中から true データと同数のデータをランダムにサンプリングした。結果を Table 4 に示す。

全感情クラスの重み付き平均正解率は 0.83 となった。正解率が低い“リラックス・気楽”は“余裕・嬉しい”と、“軽蔑”は“怒り”と感情平面における位置が近いことから、これらが混同された恐れがある。

5.3 複数の感情による多クラス判別実験

本節では、11 種類の多クラス分類実験を行った。評価人数が最も多くかつ 8 人以上である感情を正解タグとして、実験データを収集

Table 3 Names of 12 functionals

特徴量	意味	
max	最大値	
min	最小値	
range	max-min (レンジ)	
maxPos	絶対値の	最大
minPos		最小
amean	算術平均	
linregc1	線形近似の 外形の	勾配
linregc2		オフセット
linregerrQ		二乗誤差
stddev	標準偏差	
skewness	歪度	
kurtosis	尖度	

Table 4 Binary classification result for each emotion class

	正解率	データ数 (true+false)
狂喜・楽しい	0.88	138
余裕・嬉しい	0.87	374
リラックス・気楽	0.72	272
眠い・疲れた	0.85	162
冷静	0.84	252
不安・緊張	0.87	434
憂鬱・悲しい	0.88	256
恐れ	0.84	174
怒り	0.79	430
嫌い	0.80	360
軽蔑	0.76	98

した。感情ごとのデータ数を Table 5 に示す。

Table 5 のデータを用いて機械学習を行い、

Table 5 Number of training data

感情クラス	実験データ数
狂喜・楽しい	35
余裕・嬉しい	138
リラックス・気楽	126
眠い・疲れた	81
冷静	126
不安・緊張	180
憂鬱・悲しい	118
恐れ	40
怒り	175
嫌い	109
軽蔑	35
合計	1,163

Leave-one-out 交差検定で性能を評価した。結果を Table 6 に示す。また、最もデータ数の少ない“軽蔑”を除外し、感情評定結果において共起頻度が高かった“狂喜・楽しい”と“余裕・嬉しい”，“不安・緊張”と“恐れ”をグループ化してデータ数を揃え，8 クラス分類実験を行った結果を Table 7 に示す。

Table 6 より，11 クラス分類器の正解率は 0.43 であった。これはチャンスレベルの 0.14 より有意に高い値である。感情別にみると，③リラックス・気楽，⑥不安・緊張，⑨怒りを⑤冷静と誤認識している事例が多くみられた。また，⑥不安・緊張と⑧恐れの混同や，⑨怒りと⑩嫌いの混同も多くみられた。

また Table 7 より，8 クラス分類器の正解率は 0.52 であった。これはチャンスレベルの 0.13 より有意に高い値である。どの感情クラスでも平均的に正解率は高くなっていたが，11 クラス分類でも生じていた③リラックス・気楽と⑤冷静の混同と⑨怒りと⑩嫌いの混同は引き続きみられた。

6 今後の課題

まず残り 3,960 発話について知覚感情ラベルを付与する。また、演技感情と知覚感情の関係について分析する。構築したコーパスは研究用途限定で無償公開する予定である。

謝辞

本研究は国立研究開発法人科学技術振興機構(JST)の研究成果展開事業「センター・オブ・イノベーション(COI)プログラム」及び

Table 6 11-class classification result

		predict											再現率
		①	②	③	④	⑤	⑥	⑦	⑧	⑨	⑩	⑪	
answer	①	20	3	1	0	4	0	1	1	2	2	1	0.57
	②	8	58	16	10	15	5	4	7	8	2	5	0.42
	③	3	7	49	9	25	6	7	2	7	5	6	0.39
	④	0	6	4	43	7	5	1	1	4	6	4	0.53
	⑤	3	5	8	4	64	13	6	5	6	4	8	0.51
	⑥	7	11	7	12	19	62	13	17	6	12	14	0.34
	⑦	3	7	1	7	10	9	46	7	5	13	10	0.39
	⑧	2	0	1	2	2	0	1	27	0	2	3	0.68
	⑨	7	7	14	14	16	9	14	10	55	16	13	0.31
	⑩	1	3	5	6	11	5	6	4	4	51	13	0.47
	⑪	1	0	2	0	2	1	1	1	0	2	25	0.71
精度		0.36	0.54	0.45	0.40	0.37	0.54	0.46	0.33	0.57	0.44	0.25	

Table 7 8-class classification result

		predict								再現率
		① ②	③	④	⑤	⑥ ⑧	⑦	⑨	⑩	
answer	①②	42	6	3	8	7	6	7	2	0.52
	③	4	37	6	16	6	5	1	6	0.46
	④	4	5	43	8	4	5	2	10	0.53
	⑤	7	3	1	45	8	7	3	7	0.56
	⑥⑧	6	2	6	8	45	7	2	5	0.56
	⑦	6	2	4	6	8	43	5	7	0.53
	⑨	4	6	7	5	6	6	34	13	0.42
	⑩	4	3	5	6	8	6	0	49	0.60
精度		0.55	0.58	0.57	0.44	0.49	0.51	0.63	0.49	

JSPS 科研費 26330313 の助成を受けた。また、演技音声収録においてヒューマンアカデミー広島校パフォーミングアーツカレッジ様にご協力いただいた。

参考文献

- [1] Schuller *et al.*, INTERSPEECH 2009, 312-315, 2009.
- [2] 神田, 日本音響学会誌, 73(1), 31-38, 2017.
- [3] Batliner *et al.*, Proc. of a Satellite Workshop of LREC 2008 on Corpora for Research on Emotion and Affect, 28-31, 2008.
- [4] 有本, 河津, 日本音響学会 2013 年秋季研究発表会講演論文集, 1-P-46a, 385-388, 2013.
- [5] Takahashi *et al.*, Proc. of IWSDS2016, 2016.
- [6] Russell *et al.*, Journal of Personality and Social Psychology 39, 1161-1178, 1980.
- [7] 高木他, 認知科学, 21(3), 344-362, 2014.